LAPORAN UJIAN TENGAH SEMESTER
PRAKTIKUM PENELUSURAN INFORMASI

MULTI-DATASET INFORMATION RETRIEVAL SYSTEM (CLI-BASED)

Disusun oleh:

Kelompok: [ISI NOMOR KELOMPOK]

[NAMA ANGGOTA 1 - NPM]

[NAMA ANGGOTA 2 - NPM]

[NAMA ANGGOTA 3 - NPM]

DEPARTEMEN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA

2026

1. Pendahuluan

1.1 Latar Belakang

Sistem penelusuran informasi (Information Retrieval/IR) digunakan untuk mencari dokumen yang relevan terhadap kebutuhan informasi pengguna. Pada proyek ini dibangun sistem IR berbasis Command-Line Interface (CLI) yang menggabungkan lima sumber teks nyata, yaitu etd-usk, etd-ugm, Kompas, Tempo, dan Mojok. Sistem menjalankan pipeline mulai dari preprocessing, indexing, pencarian kandidat dokumen, representasi Bag of Words, hingga ranking menggunakan cosine similarity.

1.2 Tujuan

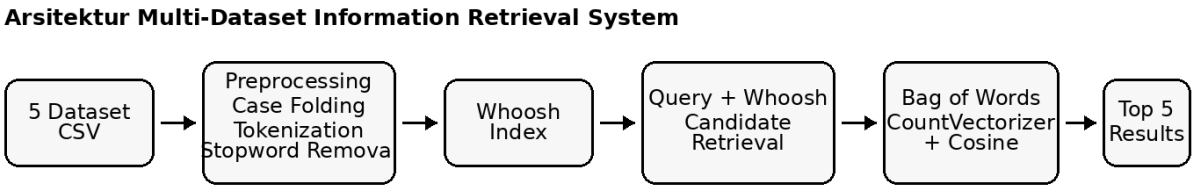
- Membangun pipeline lengkap sistem IR dari preprocessing hingga ranking.
- Mengintegrasikan lima dataset berbeda dalam satu sistem pencarian.
- Menggunakan Whoosh untuk indexing dan candidate retrieval.
- Merepresentasikan query dan dokumen dengan Bag of Words menggunakan CountVectorizer.
- Mengurutkan hasil berdasarkan cosine similarity dan menampilkan lima dokumen teratas.

1.3 Dataset

No.	Dataset	Jumlah Dokumen
1	etd-usk	10,000
2	etd-ugm	10,000
3	kompas	10,000
4	tempo	10,000
5	mojok	9,484
	Total	49,484

2. Desain Sistem dan Arsitektur

2.1 Arsitektur Sistem



Gambar 1. Arsitektur Multi-Dataset Information Retrieval System

Lima dataset dibaca menggunakan pandas. Judul dan konten digabungkan lalu diproses melalui case folding, tokenization, dan stopword removal. Hasil preprocessing disimpan pada Whoosh index. Ketika pengguna memasukkan query, Whoosh mengambil kandidat dokumen yang mengandung term relevan. Kandidat tersebut kemudian bersama query

direpresentasikan sebagai vektor Bag of Words menggunakan CountVectorizer. Nilai cosine similarity dihitung antara vektor query dan vektor setiap kandidat. Lima skor tertinggi ditampilkan kepada pengguna.

2.2 Struktur Folder

```
project/
├── main.py
├── ir_system.py
├── preprocessing.py
├── requirements.txt
├── README.md
├── sample_queries.txt
├── tests/
│   └── test_preprocessing.py
└── datasets/
    ├── etd-usk/data.csv
    ├── etd-ugm/data.csv
    ├── kompas/data.csv
    ├── tempo/data.csv
    └── mojok/data.csv
```

2.3 Alur Pencarian

1. Pengguna memasukkan query melalui CLI.

2. Query dipreprocess menggunakan fungsi yang sama dengan dokumen.

3. Whoosh melakukan candidate retrieval dari inverted index.

4. Query dan kandidat diubah menjadi matriks Bag of Words.

5. Cosine similarity dihitung antara query dan seluruh kandidat.

6. Dokumen diurutkan menurun berdasarkan skor cosine similarity.

7. Sistem menampilkan lima dokumen teratas beserta sumber dan cuplikan.

3. Implementasi

3.1 Preprocessing dan Tokenisasi

Preprocessing diimplementasikan tanpa library NLP tambahan agar tetap mengikuti batasan library. Case folding mengubah seluruh karakter menjadi huruf kecil. Tokenization menggunakan regular expression untuk mengambil term alfanumerik. Stopword removal dilakukan menggunakan daftar stopword Bahasa Indonesia yang disimpan langsung di kode.

```
def preprocess(text: str) -> str:
    return " ".join(remove_stopwords(tokenize(text)))
```

3.2 Indexing dengan Whoosh

Whoosh digunakan untuk membentuk inverted index. Field doc_id dan source disimpan sebagai ID, title sebagai TEXT tersimpan, content sebagai STORED, dan processed sebagai TEXT. Field processed menjadi field utama untuk query.

```
schema = Schema(
    doc_id=ID(stored=True, unique=True),
    source=ID(stored=True),
    title=TEXT(stored=True),
    content=STORED,
    processed=TEXT(stored=True),
)
```

3.3 Representasi Bag of Words dan Cosine Similarity

Setelah kandidat diperoleh dari Whoosh, query dan kandidat direpresentasikan menggunakan CountVectorizer. Representasi ini menghasilkan matriks Bag of Words. Cosine similarity kemudian digunakan sebagai skor akhir untuk menentukan kedekatan arah vektor query terhadap dokumen.

```
corpus = [query_processed] + [c["processed"] for c in candidates]
vectorizer = CountVectorizer(token_pattern=r"(?u)\b\w+\b")
matrix = vectorizer.fit_transform(corpus)
similarities = cosine_similarity(matrix[0:1], matrix[1:]).flatten()
```

3.4 Antarmuka CLI

```
=== INFORMATION RETRIEVAL SYSTEM ===
[1] Load & Index Dataset
[2] Search Query
[3] Exit
====================================
```

Menu pertama digunakan untuk memuat lima dataset dan membentuk index. Menu kedua melakukan pencarian. Menu ketiga mengakhiri program. Sistem menampilkan rank, judul, dataset sumber, skor cosine similarity, dan cuplikan konten.

3.5 Pengujian Unit Preprocessing

Empat unit test disediakan untuk case folding, tokenization, stopword removal, dan fungsi preprocess. Seluruh test berhasil dijalankan tanpa kegagalan.

```
Ran 4 tests in 0.000s
OK
```

4. Pengujian Query dan Analisis Hasil

Bagian ini menggunakan tiga query representatif untuk menguji kemampuan ranking pada dataset. Nilai cosine yang lebih besar menunjukkan kemiripan term yang lebih tinggi antara query dan dokumen.

4.1 Query: "machine learning prediksi harga apartemen"

Rank	Dataset	Judul	Cosine
1	etd-ugm	PREDIKSI HARGA APARTEMEN DENGAN MEMPERTIMBANGKAN FAKTOR SOCIO ECONOMIC DAN CRIME RATES DI DKI JAKARTA	0.4503
2	etd-ugm	LEARNING ANALYTICS: IMPLEMENTASI DAN VISUALISASI MACHINE LEARNING UNTUK MEMPREDIKSI HASIL BELAJAR PADA LEARNING MANAGEMENT SYSTEM (LMS) / DASHBOARD	0.3309
3	kompas	Harga Kompetitif: Penjelasan dan Alasan Penting dalam Bisnis	0.3176
4	etd-ugm	TREN PERKEMBANGAN DAN PASAR HUNIAN APARTEMEN DI KOTA SEMARANG	0.3168
5	kompas	Ini Cara Menentukan Harga Kompetitif dalam Bisnis Beserta Tipsnya	0.3074

Hasil teratas berasal dari ETD UGM dan memiliki judul yang secara langsung memuat konsep prediksi harga apartemen serta machine learning, sehingga relevansi lexical dan cosine tinggi.

4.2 Query: "pembelajaran matematika mind mapping"

Rank	Dataset	Judul	Cosine
1	mojok	Pembelajaran Matematika Seharusnya SESAT, Maksudnya Seru, Serius, Aplikatif, dan Transformatif	0.3876
2	etd-usk	MENGIDENTIFIKASI SOCIOMATHEMATICAL NORM SISWA MELALUI PROJEK GAME DENGAN KONTEKS STUNTING BERBANTUAN AUGMENTED REALITY PADA MATERI STATISTIKA	0.3627
3	etd-usk	PEMAHAMAN KONSEP DAN MOTIVASI PESERTA DIDIK SMP MELALUI PENDEKATAN SAINTIFIK BERBANTUAN TEKNIK MIND MAPPING DALAM PEMBELAJARAN MATEMATIKA	0.3596

Rank	Dataset	Judul	Cosine
4	etd-usk	IMPLEMENTASI MODEL PEMBELAJARAN MIND MAPPING DENGAN MENGGUNAKAN MEDIA BERBASIS APLIKASI CANVA UNTUK MENINGKATKAN KREATIVITAS SISWA DI SMP NEGERI 13 BANDA ACEH	0.3588
5	mojok	5 Istilah Rancangan Pembelajaran yang Krusial dan Wajib Dipahami Mahasiswa Keguruan	0.3524

Hasil memperlihatkan dokumen bertema pembelajaran matematika dari beberapa sumber. Dokumen ETD USK yang secara eksplisit membahas mind mapping muncul pada peringkat atas, menunjukkan sistem mampu menarik dokumen akademik yang relevan meskipun terdapat artikel populer dengan istilah serupa.

4.3 Query: "pesawat penerbangan"

Rank	Dataset	Judul	Cosine
1	tempo	Ibu Hamil Melahirkan di Pesawat Penerbangan Dialihkan	0.5506
2	kompas	Kisah Penerbangan TWA 847, Insiden Pembajakan Pesawat Terlama Sepanjang Sejarah	0.5355
3	tempo	Desain dan Warna Pesawat Kepresidenan RI dari Era Soekarno hingga Prabowo	0.5305
4	kompas	Berapa Ketinggian Maksimal Pesawat Terbang di Angkasa?	0.5171
5	etd-usk	PENERAPAN SUPPORT VECTOR MACHINE (SVM) DALAM MEMPREDIKSI JALUR PENERBANGAN PESAWAT SAAT KEHILANGAN KONTAK DARI PANTAUAN RADAR AIR TRAFFIC CONTROL (ATC) (STUDI KASUS: PESAWAT DL234)	0.5163

Query umum menghasilkan campuran berita Kompas, Tempo, dan dokumen akademik ETD USK. Hal ini menunjukkan sistem dapat melakukan pencarian lintas-dataset dan tidak membatasi hasil pada satu jenis sumber.

4.4 Analisis Umum

- Whoosh cocok digunakan sebagai tahap candidate retrieval karena inverted index mengurangi jumlah dokumen yang perlu dibandingkan pada tahap ranking.

- CountVectorizer memenuhi kebutuhan representasi Bag of Words dan menghasilkan vektor sparse yang efisien.
- Cosine similarity menghasilkan skor yang mudah dibandingkan dan cocok untuk ranking dokumen berbasis term.
- Karena pendekatan menggunakan lexical matching, sinonim yang tidak berbagi term dapat memiliki skor rendah walaupun secara semantik berhubungan.
- Kualitas hasil dapat ditingkatkan di masa depan melalui stemming/lemmatization, perluasan stopword, query expansion, atau pembobotan TF-IDF; namun implementasi UTS ini mempertahankan CountVectorizer sesuai instruksi.

5. Kesimpulan

Sistem Multi-Dataset Information Retrieval berbasis CLI berhasil dirancang untuk menggabungkan lima dataset dengan total 49.484 dokumen. Pipeline terdiri atas preprocessing, Whoosh indexing, pencarian kandidat, representasi Bag of Words menggunakan CountVectorizer, dan ranking menggunakan cosine similarity. Struktur program dipisahkan menjadi modul preprocessing, core IR, dan CLI sehingga mudah dibaca dan dikembangkan. Sistem menampilkan lima dokumen teratas sesuai kebutuhan proyek UTS.

Lampiran: Cara Menjalankan

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python main.py
```

Catatan: sebelum dikumpulkan, isi nomor kelompok dan identitas anggota pada cover serta README, kemudian ambil screenshot hasil eksekusi CLI pada komputer tim untuk dokumentasi presentasi/laporan bila diminta asisten.